# 1 Метод к ближайших соседей

10% баллов за задание, оценочное время выполнения: 20 минут

Сгенерируйте обучающую выборку из описанных двумя признаками объектов нескольких классов и визуализируйте разделяющие поверхности, получаемые при решении задачи классификации методом к ближайших соседей для разных k. Попробуйте подобрать оптимальное значение количества соседей k с помощью 5-fold cross-validation, построив график зависимости ассигасу в кросс-валидации от k.

# In [25]:

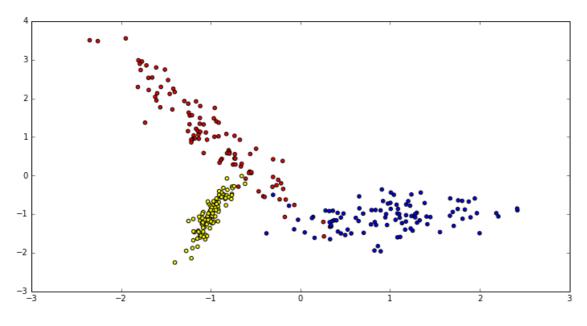
```
import numpy as np
import matplotlib.pyplot as plt

from sklearn import cross_validation, datasets, metrics, neighbors
from sklearn.model_selection import cross_val_score
from matplotlib.colors import ListedColormap
```

#### In [26]:

### Out[26]:

<matplotlib.collections.PathCollection at 0x7f0a31823ad0>



## In [27]:

```
train_data, test_data, train_labels, test_labels = cross_validation.train_test_s
plit(sample[0], sample[1],
    test_size = 0.3, random_state = 1)
```

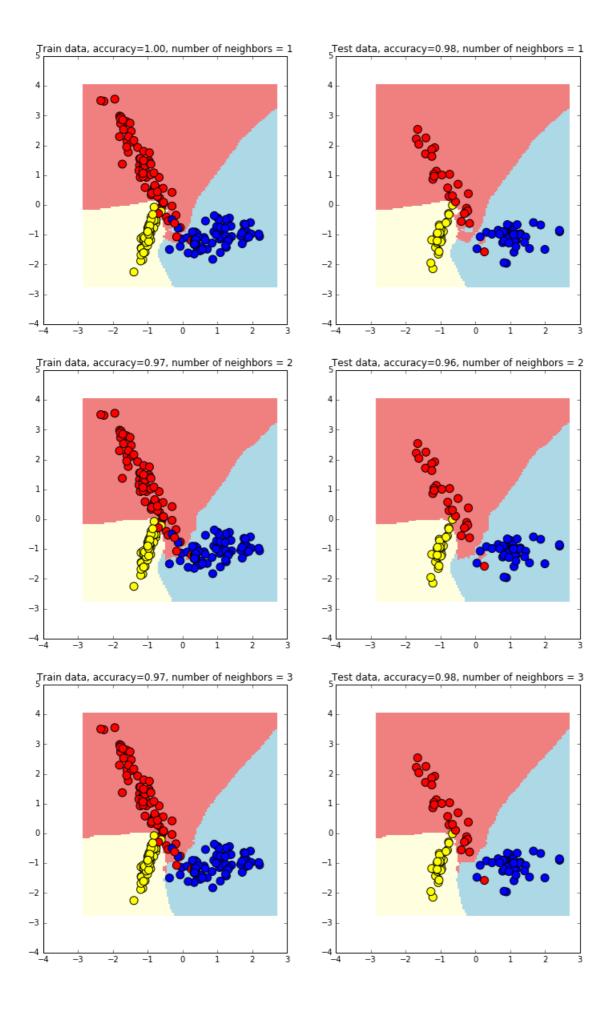
# In [28]:

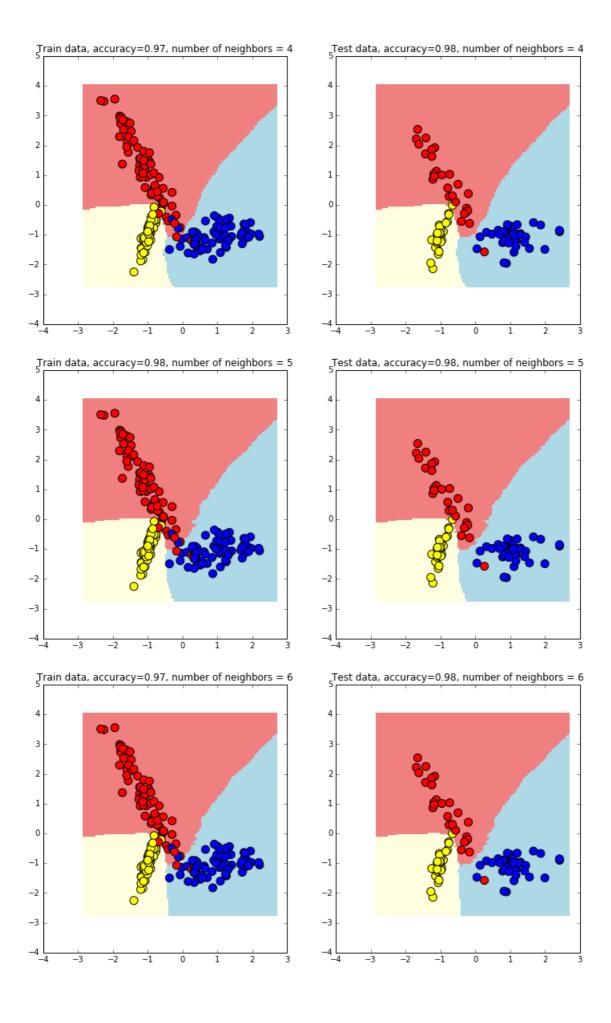
```
def get_meshgrid(data, step=.05, border=.5,):
    x_min, x_max = data[:, 0].min() - border, data[:, 0].max() + border
    y_min, y_max = data[:, 1].min() - border, data[:, 1].max() + border
    return np.meshgrid(np.arange(x_min, x_max, step), np.arange(y_min, y_max, step))
```

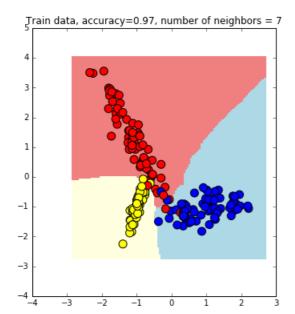
```
def plot decision surface(estimator, train data, train labels, test data, test l
abels, i,
                          colors = colors, light_colors = light_colors):
    #fit model
    estimator.fit(train data, train labels)
    plt.figure(figsize = (12, 6))
    #plot decision surface on the train data
    plt.subplot(1,2,1)
    xx, yy = get meshgrid(train data)
    mesh predictions = np.array(estimator.predict(np.c [xx.ravel(),
yy.ravel()])).reshape(xx.shape)
    plt.pcolormesh(xx, yy, mesh predictions, cmap = light colors)
    plt.scatter(train_data[:, 0], train_data[:, 1], c = train_labels, s = 100, c
map = colors)
    plt.title('Train data, accuracy={:.2f}, number of neighbors = {}'.format(met
rics.accuracy score(train labels, estimator.predict(train data)), i))
    #plot decision surface on the test data
    plt.subplot(1,2,2)
    plt.pcolormesh(xx, yy, mesh predictions, cmap = light colors)
    plt.scatter(test data[:, 0], test data[:, 1], c = test labels, s = 100, cmap
 = colors)
    plt.title('Test data, accuracy={:.2f}, number of neighbors = {}'.format(metr
ics.accuracy score(test labels, estimator.predict(test data)), i))
```

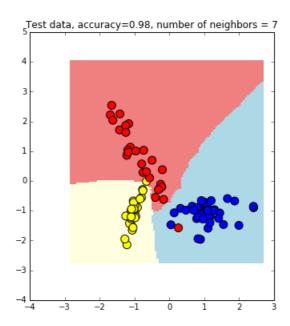
# In [42]:

```
#визуализируйте разделяющие поверхности, получаемые при решении задачи классифик ации методом k ближайших соседей для разных k #KNeighborsClassifier
N = 7
for i in range(N + 1)[1:]:
    estimator = neighbors.KNeighborsClassifier(n_neighbors=i)
    plot_decision_surface(estimator, train_data, train_labels, test_data, test_l abels, i)
```









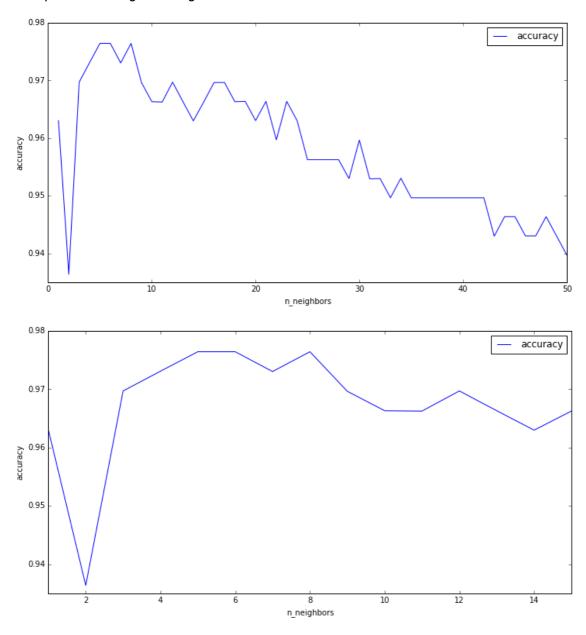
## In [46]:

```
#Попробуйте подобрать оптимальное значение количества соседей k с помощью 5-fold
cross-validation,
#построив график зависимости accuracy в кросс-валидации от k.
N = 50
accuracy = np.zeros(N)
for i in range (N + 1)[1:]:
    estimator = neighbors.KNeighborsClassifier(n neighbors = i)
    accuracy[i - 1] = np.mean(cross_val_score(estimator, sample[0], sample[1], c
v = 5)
#print accuracy
print 'Max accuracy', np.max(accuracy)
print 'Number of neighbors with max accuracy', np.argmax(accuracy)
plt.figure(figsize=(12, 6))
plt.xlabel("n neighbors")
plt.ylabel("accuracy")
plt.plot(np.arange(N+1)[1:], accuracy, label = "accuracy")
plt.legend(loc = 'best')
plt.figure(figsize=(12, 6))
plt.xlabel("n neighbors")
plt.xlim((1,15))
plt.ylabel("accuracy")
plt.plot(np.arange(N+1)[1:], accuracy, label = "accuracy")
plt.legend(loc = 'best')
```

 $\begin{array}{lll} \text{Max accuracy 0.976440677966} \\ \text{Number of neighbors with max accuracy 4} \end{array}$ 

Out[46]:

<matplotlib.legend.Legend at 0x7f0a31707090>



Оптимальное значение количества соседей k = 3-10 (варьируется при разных выборках)